SmartGlass

MINERÍA DE DATOS · REGRESIÓN

Informe metodológico

Proceso de minería de datos para construir un modelo predictivo que estime las emisiones de CO_2 de piezas de vidrio a medida en SmartGlass.

Cifras corregidas y comparación con modelos de referencia

INTEGRANTES

Javier Berrio

Argenis Caro

Miguel Martinez

LÍDER DE PROYECTO DE AULA

Ing. Cristian Camilo Cuadrado Beltrán

SECCIÓN 1

1 Introducción y problema

SmartGlass es un aplicativo web para la industria del vidrio que reúne inventario, catálogo, cotización de piezas a medida, pedidos y facturación, y que muestra la huella de carbono (CO_2) de cada pieza antes de fabricarla. Las vidrierías no suelen tener herramientas para cuantificar las emisiones de la fundición y el procesado de piezas a medida.

Este informe documenta el proceso de minería de datos realizado para construir un modelo que estime las emisiones de CO_2 a partir de las características técnicas de cada pieza, como apoyo a los objetivos de sostenibilidad del proyecto y a la meta de carbono-neutralidad de la Ley 2169 de 2021.

ODS 9 · ODS 12 · ODS 13 · Ley 2169 de 2021

SECCIÓN 2

2 Fuente y descripción de los datos

Como el aplicativo todavía no opera con una vidriería real (situación C de la guía), se generó un dataset sintético basado en factores de emisión publicados.

Fuente

Factores de emisión de Branca et al. (2020), MITECO (2013) y Guardian Glass, implementados en el script **data/generacion_dataset.py**.

Estructura

1.000 registros y **8 columnas** que simulan piezas de **20 tipos de vidrio** del catálogo de SmartGlass. El CO_2 va de 9,20 a 1.063,61 kg por pieza, con un promedio de 212,17 kg.

float · crudo · incoloro · templado · laminado · blindado · antivandálico · bajo_emisivo · insulado · termoreflector · esmerilado · tintado · reflectivo · texturizado · antirreflejo · acústico · cortafuego · fotovoltaico · inteligente · reciclado

6 VARIABLES PREDICTORAS

tipo_vidrio · proceso · area_m2 · espesor_mm · calcin_pct · energia_kwh_kg

1 VARIABLE EXCLUIDA

masa_kg: se calcula con la misma fórmula que el CO_2 (ver sección 4).

1 VARIABLE OBJETIVO

co2_kg

SECCIÓN 3

3 Metodología y uso de MinedApp

El análisis siguió las **6 etapas** propuestas por la herramienta MinedApp como guía estructurada.

1 Problema
Tarea de regresión para predecir co2_kg.

2 Datos
Carga del CSV y estadísticas descriptivas en MinedApp.

3 Preprocesamiento
One-Hot para categóricas, exclusión de masa_kg y división 80/20.

4 Modelado
Random Forest Regressor (200 árboles) dentro de un Pipeline.

5 Evaluación
MAE, RMSE y R^2, validación cruzada y dos modelos de referencia.

6 Reporte
Este informe y la documentación en el repositorio.

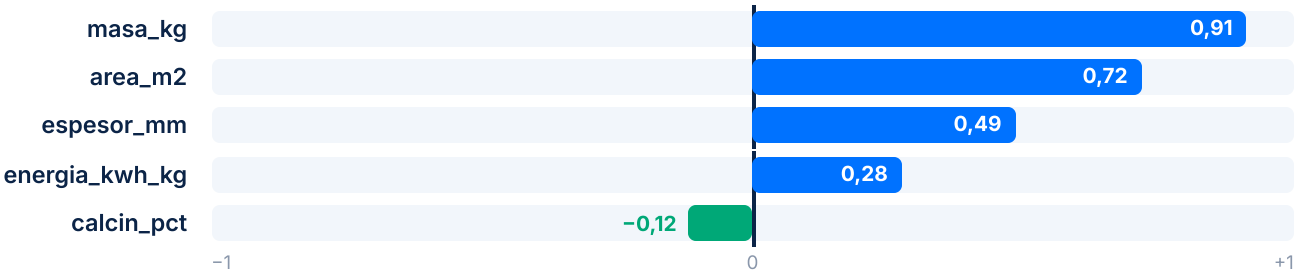
SECCIÓN 4

4 Exploración y preparación

CALIDAD
Sin valores nulos ni duplicados, por construcción del dataset.

VALORES ATÍPICOS
Valores altos en area_m2 y co2_kg. Son piezas de gran formato (por ejemplo, fachadas) y se conservan como registros válidos.

Correlaciones con co2_kg



El CO_2 depende sobre todo del tamaño de la pieza. El calcín (vidrio reciclado) tiene una relación **negativa pero débil** (−0,12): más reciclado, menos CO_2.

> **Preparación**
> One-Hot Encoding para tipo_vidrio y proceso, dentro de un Pipeline de scikit-learn. Se excluyó **masa_kg** porque se calcula como área × espesor × 2,5, la misma fórmula que genera el CO_2: dejarla sería darle al modelo parte de la respuesta (*filtración de datos*).

SECCIÓN 5

5 Modelo y evaluación

ALGORITMO

Random Forest Regressor

200 árboles, semilla 42, en un Pipeline de scikit-learn junto con el One-Hot Encoding.

DIVISIÓN DE DATOS

80 % · 20 %

800 registros de entrenamiento y **200** de prueba, división aleatoria con semilla 42 (sin estratificar).

Métricas en el conjunto de prueba

23,25 kg

MAE · el modelo se equivoca en promedio 23,25 kg de CO_2 por pieza.

33,22 kg

RMSE · raíz del error cuadrático medio; castiga más los errores grandes.

0,9433

R^2 · el modelo explica el 94,3 % de la variación de las emisiones.

VALIDACIÓN CRUZADA (5 PARTICIONES)

0,9271 ± 0,0115

R^2 promedio en 5 particiones (rango 0,9108 a 0,9414). Es la cifra más confiable para presentar: no depende de una sola división de los datos.

Comparación con modelos de referencia

MODELO	MAE (KG)	RMSE (KG)	R^2 PRUEBA	R^2 VALIDACIÓN CRUZADA
Media (modelo ingenuo)	111,61	140,41	−0,012	−0,004
Regresión lineal	34,41	48,37	0,880	0,878 ± 0,018
Random Forest	**23,25**	**33,22**	**0,943**	**0,927 ± 0,012**

Mismas variables, misma división y mismo Pipeline para los tres modelos. Random Forest reduce el error medio un 32 % frente a la regresión lineal y un 79 % frente a predecir siempre el promedio.

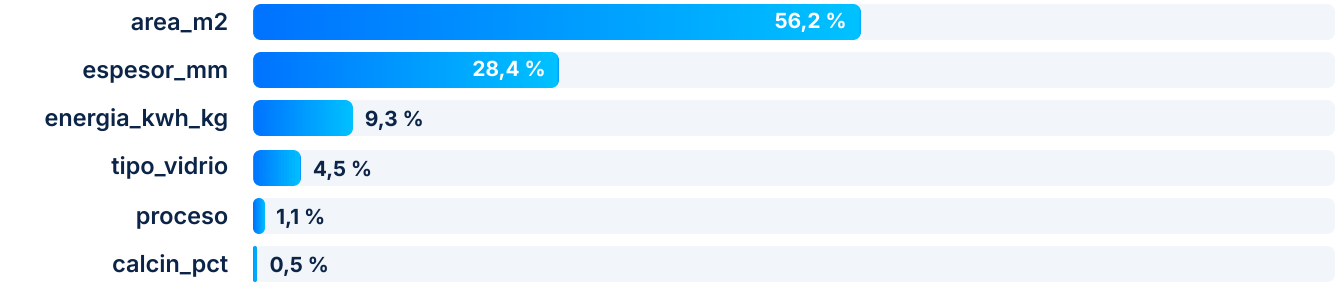
> **Sobreajuste**
>
> En entrenamiento el modelo logra R^2 0,9903 (MAE 9,65 kg) y en prueba 0,9433 (MAE 23,25 kg). La diferencia indica algo de sobreajuste: los árboles memorizan parte del entrenamiento. Por eso la cifra para presentar es la de validación cruzada, que se mantiene estable entre particiones (± 0,0115).

SECCIÓN 6

6 Resultados e interpretación

La importancia de variables (*feature importance*) del modelo final, sin masa_kg, muestra que el **tamaño de la pieza** decide casi todo: área y espesor suman el 84,6 %.

Importancia de cada variable en el modelo



tipo_vidrio y proceso suman sus columnas One-Hot.

TAMAÑO

Fundir más vidrio emite más CO_2: por eso área y espesor dominan, igual que en el cálculo por etapas de la app.

TIPO Y PROCESO

Una vez conocido el tamaño, el tipo de vidrio y el proceso aportan poco (5,6 % juntos).

RECICLADO

Las piezas de vidrio reciclado promedian 123 kg de CO_2, frente a 182 kg del float.

ACTUALIZACIÓN

↺ Qué cambió respecto a la versión anterior

DATO	ANTES	AHORA	POR QUÉ
MAE (prueba)	20,69 kg	23,25 kg	La versión anterior usaba masa_kg, que repite la fórmula del CO_2. Al quitarla, el error sube un poco pero el resultado es honesto.
RMSE (prueba)	33,49 kg	33,22 kg	
R^2 (prueba)	0,9461	0,9433	
R^2 validación cruzada	0,9456 ± 0,0123	0,9271 ± 0,0115	
Correlaciones con co2_kg	masa 0,98; calcín −0,45	masa 0,91; calcín −0,12	Recalculadas sobre el dataset del repositorio.
División de datos	estratificada	aleatoria	El notebook no estratifica por tipo_vidrio.
Variables más importantes	masa y tipo	área y espesor	Se recalculó sin masa_kg; el tipo de vidrio pesa 4,5 %.
Modelos de referencia	no reportados	media y lineal	Se agregaron con la misma división y el mismo Pipeline.

SECCIÓN 7

7 Limitaciones y conclusiones

Limitaciones

Datos teóricos: el modelo aprendió de fórmulas, no de mediciones de hornos reales; habrá que reentrenarlo con datos de planta.

No está integrado en la app: el aplicativo calcula el CO_2 con su propio método por etapas (fusión, templado, PVB, capa activa y transporte), con otros factores (por ejemplo, la red eléctrica a 0,220 en vez de 0,25 kg CO_2/kWh) y 7 tipos de vidrio en vez de 20.

Tipos poco representados: fotovoltaico tiene 3 registros, inteligente 6, y cortafuego, antirreflejo y reciclado menos de 10; sus estimaciones son menos confiables.

Sobreajuste moderado: la diferencia entre entrenamiento y prueba aconseja ajustar la profundidad de los árboles en una siguiente versión.

CONCLUSIÓN

Es viable estimar el CO_2 de una pieza de vidrio a partir de sus parámetros técnicos: Random Forest explica el 92,7 % de la variación en validación cruzada y supera con claridad a la regresión lineal y al promedio. El modelo sirve como base para un futuro servicio de «segunda opinión» junto al cálculo por etapas del aplicativo, en apoyo de las historias de usuario **US-09** y **US-13**. El siguiente paso es reentrenarlo con mediciones de una vidriería durante el piloto.

SECCIÓN 8

8 Referencias y repositorio

Branca, T. A., Colla, V., & Algermissen, D. (2020). Reducing CO_2 emissions in energy-intensive industries. *Energy, 211*, 118650.

MITECO (2013). *Fabricación de vidrio: Proceso.* Ministerio para la Transición Ecológica.

Guardian Glass. *How glass is made.*

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

REPOSITORIO DEL PROYECTO

https://github.com/OpTicXit/Smartglass

Notebook: **mineria de datos/analisis.ipynb** · métricas: **mineria de datos/metricas_modelo.csv** · dataset: **data/raw/smartglass_co2.csv**