SmartGlass

FORMATO DE PROPUESTA

Modelo predictivo de huella de carbono

SmartGlass: aplicativo web para la optimización de procesos productivos, gestión comercial y monitoreo de huella de carbono en la industria del vidrio.

Resultados corregidos y comparación con modelos de referencia

INTEGRANTES

Javier Berrio

Argenis Caro

Miguel Martinez

LÍDER DE PROYECTO DE AULA

Ing. Cristian Camilo Cuadrado Beltrán

SECCIÓN A

A Identificación del proyecto

NOMBRE DEL PROYECTO

SmartGlass: aplicativo web para la optimización de procesos productivos, gestión comercial y monitoreo de huella de carbono en la industria del vidrio.

INTEGRANTES

Javier Berrio
Argenis Caro
Miguel Martinez

LÍDER DE PROYECTO DE AULA

Ing. Cristian Camilo Cuadrado Beltrán

FECHA

Octubre 2026

REPOSITORIO

https://github.com/OpTicXit/Smartglass

SECCIÓN B

B El problema

¿Qué situación aborda el proyecto?

La industria del vidrio en Colombia opera con opacidad ambiental: las empresas desconocen la huella de carbono (CO_2) de la fabricación de piezas a medida. Eso les impide demostrar avances frente a la meta de carbono-neutralidad de la **Ley 2169 de 2021** y les hace perder oportunidades en el mercado sostenible.

¿Qué pregunta se busca responder?

¿Es posible estimar con precisión las emisiones de CO_2 (en kg) de una pieza de vidrio personalizada a partir de sus parámetros técnicos (tipo, dimensiones, proceso y % de material reciclado) antes de fabricarla?

¿Por qué sería útil estudiar esa situación mediante datos?

Permitiría integrar un «sello ambiental» en tiempo real en el cotizador del aplicativo, facilitar reportes de sostenibilidad, recomendar alternativas de menor impacto y ayudar a los clientes a tomar decisiones informadas.

SECCIÓN C

Datos

1000 registros × **8** columnas

VARIABLE OBJETIVO

co2_kg

Numérica continua · kg de CO_2 emitidos (de 9,20 a 1.063,61; promedio 212,17)

Fuente y enlace

Dataset derivado de factores de emisión documentados en literatura técnica (Branca et al., 2020; MITECO, 2013; Guardian Glass). Generado con el script **data/generacion_dataset.py** del repositorio para garantizar reproducibilidad (situación C de la guía: proyecto en desarrollo).

Variables

tipo_vidrio · 20 categorías del catálogo

proceso · 4 categorías

area_m2

espesor_mm

calcin_pct

energia_kwh_kg

masa_kg · derivada

co2_kg · objetivo

Problemas de calidad identificados

NULOS Y DUPLICADOS

Al ser un dataset derivado de fórmulas físicas, no presenta valores nulos ni duplicados.

VALORES ATÍPICOS

Los detectados (piezas de gran formato) son registros válidos del proceso y se conservan.

VARIABLE QUE FILTRA LA RESPUESTA

masa_kg se calcula como área × espesor × 2,5, la misma fórmula que genera el CO_2. Si se usa, el modelo «copia» la respuesta; por eso se excluye.

TIPOS POCO REPRESENTADOS

Fotovoltaico tiene 3 registros e inteligente 6; sus estimaciones serán menos confiables.

SECCIÓN D

D Modelo propuesto

TIPO DE TAREA

Regresión

Estimación de un valor numérico continuo.

ALGORITMO PROPUESTO

Random Forest Regressor

Justificación de la elección

Las emisiones de CO_2 dependen de relaciones no lineales entre el tamaño de la pieza (área y espesor), la energía del proceso y el tipo de vidrio. Random Forest maneja bien estas relaciones, es robusto ante valores atípicos y permite medir la importancia de cada variable (*feature importance*).

Variables predictoras

tipo_vidrio | proceso | area_m2 | espesor_mm | calcin_pct | energia_kwh_kg

~~masa_kg~~ Se excluye: repite la fórmula del CO_2 (filtración de datos).

Estrategia de preparación

Dataset 1.000 registros → **One-Hot Encoding** variables categóricas → **80 / 20** división aleatoria · semilla 42 → **800 · 200** entrenar · probar → **Random Forest** 200 árboles

PREPARACIÓN

One-Hot Encoding para las variables categóricas, dentro de un Pipeline de scikit-learn. División 80 % entrenamiento / 20 % prueba con semilla 42.

VALIDACIÓN

Además de la división fija, validación cruzada de 5 particiones para comprobar que el resultado no depende de una sola división.

SECCIÓN E

Evaluación

MAE

Error absoluto medio. Se lee en kg de CO_2: error promedio por pieza.

RMSE

Raíz del error cuadrático medio. Castiga los errores grandes, críticos en reportes ambientales.

R^2

Coeficiente de determinación. Qué parte de la variación de las emisiones explica el modelo.

MODELOS DE REFERENCIA

Para saber si el Random Forest aporta algo, se compara con dos modelos simples entrenados con las mismas variables y la misma división: la **media** de la variable objetivo (modelo ingenuo) y una **regresión lineal**.

Resultado de la comparación

MODELO	MAE (KG)	RMSE (KG)	R^2 PRUEBA	R^2 VALIDACIÓN CRUZADA
Media (modelo ingenuo)	111,61	140,41	−0,012	−0,004
Regresión lineal	34,41	48,37	0,880	0,878 ± 0,018
Random Forest	**23,25**	**33,22**	**0,943**	**0,927 ± 0,012**

Random Forest reduce el error medio un 32 % frente a la regresión lineal y un 79 % frente a predecir siempre el promedio. La media da un R^2 cercano a cero, como corresponde a un modelo que no usa ninguna variable.

SECCIÓN F

Resultado obtenido

Random Forest de 200 árboles evaluado sobre el conjunto de prueba (200 registros) y con validación cruzada de 5 particiones.

0,9433 R^2 en prueba	**23,25 kg** MAE · kg de CO_2	**33,22 kg** RMSE · kg de CO_2	**0,9271** **± 0,0115** · R^2 con validación cruzada

¿Qué decisión podría apoyarse?

Recomendación automática de materiales de menor impacto (por ejemplo, aumentar el % de calcín) para reducir la huella de carbono del pedido en el cotizador.

¿Cuáles son las principales limitaciones?

El dataset se deriva de factores teóricos: el modelo deberá reentrenarse con datos reales de planta. En entrenamiento logra R^2 0,99 y en prueba 0,94, lo que muestra algo de sobreajuste; por eso la cifra para presentar es la de validación cruzada. Hoy el modelo no está integrado en el aplicativo, que calcula el CO_2 con su propio método por etapas.

ACTUALIZACIÓN RESPECTO A LA VERSIÓN ANTERIOR

La primera versión reportaba R^2 0,9461, MAE 20,69 kg, RMSE 33,49 kg y validación cruzada 0,9456 ± 0,0123. Esas cifras incluían **masa_kg**, que repite la fórmula del CO_2. Al quitarla el error sube un poco, pero el resultado refleja lo que el modelo aprende de verdad. Detalle completo en el informe metodológico actualizado.